机器学习课程项目开题报告

基于扩散模型与流匹配的车辆轨迹生成式预测

——生成范式的对比研究

课程：机器学习 项目类型：研究型课程项目 日期：2026 年 9 月

一、研究背景与动机

自动驾驶系统中的轨迹预测模块，负责根据交通参与者的历史运动与道路结构，推断其未来数秒的运动轨迹。由于驾驶意图天然具有多模态性（例如路口处一辆车可能左转、直行或右转），传统的单点回归方法（直接最小化 MSE）在数学上倾向于输出"平均轨迹"，导致预测结果落在不可行区域，无法刻画多模态分布。

近年来，扩散模型（Diffusion Model）被引入轨迹预测与规划领域（如 Diffusion-Planner[1]、Diffusion-ES[2]），通过迭代去噪从数据分布中采样多样化轨迹；而其后继者流匹配（Flow Matching）（如 Flow-Planner[3]）以直线插值路径和确定性 ODE 求解，声称可用更少的采样步数达到同等精度。然而，"扩散"与"流匹配"两种生成范式在同一任务、同一网络架构下的严格对比仍较少被系统研究。本项目旨在控制变量地比较三种范式：确定性回归、扩散模型、流匹配，回答两个科学问题：

（1）生成式建模相比回归基线，在多模态场景下能带来多大精度与多样性收益？

（2）流匹配能否以显著更少的采样步数逼近扩散模型的预测质量？

二、任务定义

在 nuPlan 自动驾驶数据集（mini
划分）上定义条件轨迹生成任务：给定目标车辆过去 2
秒的轨迹序列及其周围车道线几何作为条件 c，生成该车辆未来 8 秒的轨迹 τ = {(x_t, y_t)}，共 80 个路径点（10 Hz）。输出坐标在目标车当前时刻的自身坐标系下表示。

三、方法设计

3.1 模型谱系

三个模型共享同一套场景编码器（MLP-Mixer 架构，编码车辆历史与车道线，输出 192 维条件向量），仅轨迹生成头不同，以保证对比公平：

模型	角色	训练目标	推理方式
A. 回归基线 (MLP)	Baseline	最小化预测轨迹与真值的 MSE	单次前向
B. 扩散模型 (DiT)	生成范式一	ϵ-预测：学习所加高斯噪声（DDPM 目标）	DPM-Solver，约 15 步

模型 B 与 C 使用完全相同的去噪网络（4 层 Diffusion Transformer，192 维，约 200 万参数），仅训练损失与采样器不同——这一设计使得"扩散 vs 流匹配"的对比归结为生成范式本身的差异，而非容量差异。

3.2 数学形式

扩散模型前向加噪：x_t = √_t · x + √(1_t) · ϵ，网络学习预测 ϵ；流匹配定义 x_t = (1t)·x + t·ϵ 的直线路径，网络学习速度场 v_θ(x_t, t, c) ≈ ϵ x，推理时从 ϵ ~ N(0, I) 出发做少步 Euler 积分即得轨迹。流匹配的 ODE 是确定性的：同一初始噪声必映射到同一轨迹，这一性质将在实验中以"同噪声重复采样一致性"加以验证。

3.3 训练配置

数据取自 nuPlan mini 划分的驾驶日志，抽取目标车辆轨迹对约 5 万~20 万条；batch size 256，AdamW 优化器，余弦学习率，训练 20~50 epoch。单卡消费级 GPU 数小时内可完成，无需分布式训练。

四、实验方案与评价指标

4.1 定量对比

主指标：minADE@K / minFDE@K（K=6 条采样中取最优）、Miss Rate。生成模型采 K 条候选，回归基线仅输出单条——该对比本身就体现多模态建模的价值。

4.2 消融与分析实验

（1）多样性-精度曲线：K ∈ {1, 4, 6, 16} 时 minADE 的变化；

（2）采样步数消融：扩散 15 步 vs 流匹配 4/8 步的精度-耗时权衡（核心论点：流匹配少步高效）；

（3）确定性验证：流匹配在同一 ϵ 下重复解码的输出一致性（L2 距离应≈0），扩散随机采样作为对照；

（4）场景分类分析：按直行 / 弯道 / 路口 / 跟车场景分别统计指标，验证"多模态收益集中于路口类场景"的假设。

4.3 定性可视化

绘制多候选轨迹与真值的叠加图（鸟瞰视角），重点展示路口场景中生成模型给出的多模态分叉（如"左转 + 直行"两簇轨迹），并与回归基线的"平均轨迹"失败案例对比。

五、预期结果与创新点

（1）生成式模型在 minADE@6 上显著优于回归基线，且在路口等多模态场景优势最大；

（2）流匹配以约 1/3 采样步数达到与扩散模型相当的精度，验证其效率优势；

（3）给出一份控制变量（同架构、同数据、同条件）的"扩散 vs 流匹配"实证对比，为后续科研（测试时噪声空间轨迹搜索）提供方法学依据。

六、进度安排（5 周）

周次	任务
第 1 周	数据管线：从 nuPlan mini 抽取车辆历史/未来轨迹对，构建 npz 训练集
第 2 周	回归基线 A 训练与评估；评价指标代码（ADE/FDE/MissRate）
第 3 周	扩散模型 B 训练与 DPM-Solver 采样跑通
第 4 周	流匹配 C（改动训练损失 + Euler 采样器）；全部对比与消融实验
第 5 周	可视化、失败案例分析、撰写报告

七、与科研工作的衔接（未来工作）

本项目验证的"流匹配少步采样保持精度"与"ODE 解码确定性"两条结论，直接支撑后续研究方向：在 Flow Matching 的噪声空间中进行进化搜索（CEM）做测试时轨迹选优——由于解码确定且产物天然位于数据流形上，可在推理阶段以少量前向计算完成"采样—打分—选优"闭环，无需额外训练。该方向融合 Diffusion-ES[2] 的进化搜索框架与 TOAD[4] 的信任区域思想。

参考文献

[1] Zheng Y, Liang J, et al. Diffusion-Based Planning for Autonomous Driving with Flexible Guidance. ICLR, 2025. arXiv:2501.15564.

[2] Yang B, Su H, Gkanatsios N, et al. Diffusion-ES: Gradient-free Planning with Diffusion for Autonomous and Instruction-Guided Driving. CVPR, 2024. arXiv:2402.06559.

[3] Tan T, Zheng Y, et al. Flow-Planner: Bridging the Gap Between Traffic Simulation and Real-World Deployment. NeurIPS, 2025.

[4] Xu et al. TOAD: Test-Time Trajectory Optimization for Autonomous Driving. arXiv:2606.07170, 2026.

[5] Caesar H, et al. nuPlan: A closed-loop ML-based planning benchmark for autonomous vehicles. CVPRW, 2021.